


Plagiarism Detection Report by SmallSEOTOOLS



Scan details

Total Words	Total Characters	Plagiarized Sentences	Unique Sentences
1025	8244	0	42 (100%)

#1 100% Unique

Laporan Final Project

Kecerdasan Buatan (Lanjut)

Implementasi SRGAN untuk Super-Resolution pada

Dataset DIV2K dan Set 5 dan 14

Kelompok 03

Anggota Kelompok:

1. 23.11.5583 Reynald Aryansyah

2. 23.11.5567 Ahmad Rafdy Ramadhan

3. 23.11.5575 M Noer Attalah Dzahkwan

4. 23.11.5579 Andri Laksono

1. Latar Belakang

Seiring pesatnya perkembangan teknologi digital, permintaan terhadap citra dengan tingkat resolusi tinggi terus meningkat (High-Resolution/HR) semakin krusial, yang diaplikasikan pada berbagai bidang strategis seperti sistem keamanan, layanan kesehatan berbasis citra, serta observasi wilayah dari udara. Namun, kendala fisik pada sensor optik sementara keterbatasan kapasitas transmisi data kerap berdampak pada dihasilkannya citra beresolusi rendah (Low-Resolution/LR). Tantangan mendasar dalam ranah Single Image Super-Resolution (SISR) terletak pada upaya memulihkan kembali komponen frekuensi tinggi yang tidak terekam pada citra beresolusi rendah agar kembali tajam dan layak analisis. Di Indonesia, penelitian terkait restorasi citra telah dikaji sebelumnya, termasuk pemanfaatan teknik interpolasi konvensional sebagai metode pembandingan [6] maupun penerapan Convolutional Neural Network (CNN) standar pada citra kompleks [5]. Namun, mayoritas pendekatan ini masih terpaku pada optimasi nilai matematis semata.

Metode konvensional seperti interpolasi Bicubic maupun arsitektur Deep Learning awal yang berbasis fungsi kerugian Mean Squared Error (MSE) memiliki keterbatasan mendasar. Meskipun metode-metode ini mampu menghasilkan nilai Peak meskipun memiliki nilai Signal-to-Noise Ratio (PSNR) yang tinggi, hasil rekonstruksi citra sering menunjukkan karakter visual terlalu halus (oversmoothed) dan kehilangan detail tekstur [1]. Fenomena ini terjadi karena minimalisasi MSE bekerja dengan

merata-ratakan probabilitas piksel, sehingga gagal mempertahankan fitur visual tajam seperti serat kain atau vegetasi yang esensial bagi persepsi mata manusia [2].

Sebagai solusi atas permasalahan tersebut, Super-Resolution Generative Adversarial Network (SRGAN) menawarkan pendekatan revolusioner melalui skema adversarial training [1]. Berbeda dengan metode deterministik, SRGAN memanfaatkan Perceptual Loss digunakan untuk mendorong model menghasilkan detail tekstur yang lebih natural dan mendekati karakteristik citra asli, suatu pendekatan yang kemudian berkembang pada arsitektur generasi lanjutan seperti ESRGAN [4]. Penelitian ini bertujuan mengimplementasikan SRGAN untuk mengurangi efek blur yang umum muncul pada pendekatan konvensional, dengan penekanan utama pada peningkatan kualitas perseptual visual (perceptual quality) meskipun harus menghadapi fenomena konsep perception–distortion trade-off yang menunjukkan bahwa peningkatan kualitas visual tidak selalu berbanding lurus dengan nilai PSNR [3].

2. Metode:

2.1. Alur Penelitian

2.2. Dataset dan Pra-pemrosesan

Dataset utama yang digunakan dalam eksperimen ini adalah DIV2K (Diverse 2K Resolution Images), yang merupakan salah satu standar paling umum dalam penelitian Super-Resolution. Dataset ini menyediakan citra resolusi tinggi dengan variasi objek, tekstur, serta kondisi pencahayaan yang beragam, sehingga sangat representatif untuk evaluasi kinerja model SR.

Sebelum digunakan sebagai input model, data mentah diproses

melalui beberapa tahapan praproses sebagai berikut.

a. Tahap pertama adalah ekstraksi patch, di mana citra resolusi tinggi (HR)

dipotong menjadi bagian-bagian kecil berukuran 128×128 piksel. Proses

langkah ini dilakukan untuk memperbanyak variasi data pelatihan

sekaligus mengoptimalkan penggunaan memori GPU selama pelatihan.

b. Tahap kedua adalah degradasi (downsampling). Untuk mensimulasikan

untuk membentuk citra beresolusi rendah (LR), setiap patch HR

mengalami proses penurunan resolusi dengan faktor skala 2

menggunakan kernel bicubic. Proses ini menghasilkan pasangan data

latih yang saling berkorespondensi antara citra LR dan HR.

c. Tahap ketiga adalah normalisasi data. Nilai intensitas piksel citra yang

semula berada pada rentang $[0, 255]$ dikonversi ke rentang floating point

$[-1, 1]$. Normalisasi ini penting untuk mempercepat konvergensi selama

proses pelatihan, khususnya karena lapisan output Generator

menggunakan fungsi aktivasi Tanh.

2.3. Arsitektur Model

a. Generator Network

Generator dirancang untuk merekonstruksi citra super-resolusi

(SR) yang memiliki karakteristik mendekati citra resolusi tinggi (HR)

berdasarkan masukan citra beresolusi rendah (LR). Arsitektur generator

mengadopsi konsep Deep Residual Network (ResNet) dengan beberapa

komponen utama. Blok residual tersusun atas beberapa lapisan konvolusi

yang menggunakan kernel berukuran 3×3 dengan 64 filter. Setiap lapisan

lapisan konvolusi yang selanjutnya dipadukan dengan Batch

Normalization (BN) serta mekanisme aktivasi non-linear Parametric ReLU (PReLU) untuk meningkatkan stabilitas pelatihan dan kemampuan representasi fitur.

Skip connection digunakan untuk menghubungkan fitur awal secara langsung ke fitur akhir. Mekanisme ini memungkinkan aliran gradien yang secara lebih stabil selama pelatihan, sehingga mampu menekan potensi terjadinya masalah vanishing gradient pada jaringan yang dalam.

Blok upsampling memanfaatkan lapisan PixelShuffle untuk meningkatkan dimensi spasial citra secara efisien. Metode ini dipilih karena mampu menghasilkan kualitas citra yang lebih baik serta meminimalkan artefak checkerboard yang sering muncul pada penggunaan transposed convolution.

Gambar 2.3.1. Gambar Generator Network

b. Discriminator Network

Discriminator berfungsi sebagai klasifikator yang bertugas membedakan apakah sebuah citra merupakan citra asli beresolusi tinggi (HR) atau citra palsu hasil rekonstruksi dari Generator (SR). Arsitektur Discriminator dirancang mengikuti pola VGG-style dengan peningkatan peningkatan jumlah filter dilakukan secara bertingkat, mulai dari 64 hingga 512, dengan tujuan mengekstraksi fitur visual yang semakin kompleks. Proses reduksi dimensi citra dilakukan menggunakan strided

convolution, sehingga ukuran spasial citra berkurang secara bertahap tanpa memerlukan lapisan pooling tambahan. Untuk fungsi aktivasi, digunakan LeakyReLU dengan nilai parameter $\alpha = 0.2$ yang bertujuan

mencegah terjadinya masalah dying ReLU serta menjaga aliran gradien tetap stabil.

Pada bagian akhir jaringan, digunakan lapisan Sigmoid untuk menghasilkan nilai probabilitas yang merepresentasikan tingkat keaslian citra, yaitu apakah citra tersebut termasuk citra HR asli atau citra SR hasil rekonstruksi Generator.

Gambar 2.3.2. Discriminator Network

2.4. Algoritma dan Strategi Pelatihan (Training Strategy)

Salah satu kontribusi utama dalam implementasi ini adalah penerapan strategi pelatihan dinamis yang membagi proses training ke dalam dua fase berdasarkan karakteristik fungsi kerugian (loss function) yang digunakan. Proses pelatihan memanfaatkan algoritma optimasi Adam dengan learning rate sebesar 10^{-4} .

Fase 1: Structural Learning (Epoch 1–25)

Pada fase awal pelatihan, tujuan utama adalah membentuk struktur global citra, seperti bentuk objek dan distribusi warna dasar, agar menyerupai citra asli. Fungsi kerugian pada fase ini didominasi oleh L1 Loss (Mean Absolute Error) yang dikombinasikan dengan Adversarial

Loss, dengan formulasi sebagai berikut:

$$L_{\text{total}} = L_{\text{L1}} + \lambda L_{\text{Adv}}$$

Penggunaan L1 Loss efektif dalam meminimalkan kesalahan pada tingkat piksel, sehingga model dapat mencapai konvergensi lebih cepat dan menghasilkan nilai PSNR yang tinggi. Meskipun citra yang dihasilkan pada tahap ini cenderung tampak halus (smooth) dan kurang detail, fase ini berperan penting dalam membangun fondasi bobot Generator yang stabil dan kuat.

Fase 2: Perceptual Refinement (Epoch 26–Selesai)

Setelah struktur dasar citra terbentuk, proses pelatihan dilanjutkan dengan fokus pada pemulihan detail frekuensi tinggi, seperti tekstur halus pada rambut, rumput, atau serat kain. Pada fase ini, L1 Loss digantikan dengan mengganti fungsi kerugian menjadi VGG Loss (Perceptual Loss)

yang dipadukan dengan Adversarial Loss, dengan

Lorem ipsum dolor sit amet consectetur. Ut enim mauris at vel mi mauris sagittis. Arcu fames lectus habitasse feugiat suspendisse. Ipsum volutpat ornare placerat sit quis semper dui pharetra. Vestibulum a ipsum aenean nisi dictum tempor. Lacinia pharetra donec aliquam egestas lectus ut turpis. Sapien quam urna in quis vivamus pretium ultrices ac hac. Elementum sit nisl elit tincidunt tortor. Adipiscing aenean mattis sit enim nibh imperdiet

Result Locked

significant plagiarism Found Go Pro for Remaining text

Go Pro