

Laporan Final Project

Kecerdasan Buatan (Lanjut)

*Implementasi SRGAN untuk Super-Resolution pada
Dataset DIV2K dan Set 5 dan 14*



Kelompok 03

Anggota Kelompok:

1. 23.11.5583 Reynald Aryansyah
2. 23.11.5567 Ahmad Rafdy Ramadhan
3. 23.11.5575 M Noer Attalah Dzahkwan
4. 23.11.5579 Andri Laksono

1. Latar Belakang

Seiring pesatnya perkembangan teknologi digital, permintaan terhadap citra dengan tingkat resolusi tinggi terus meningkat (*High-Resolution/HR*) semakin krusial, yang diaplikasikan pada berbagai bidang strategis seperti sistem keamanan, layanan kesehatan berbasis citra, serta observasi wilayah dari udara. Namun, kendala fisik pada sensor optik sementara keterbatasan kapasitas transmisi data kerap berdampak pada dihasilkannya citra beresolusi rendah (*Low-Resolution/LR*). Tantangan mendasar dalam ranah Single Image Super-Resolution (SISR) terletak pada upaya memulihkan kembali komponen frekuensi tinggi yang tidak terekam pada citra beresolusi rendah agar kembali tajam dan layak analisis. Di Indonesia, penelitian terkait restorasi citra telah dikaji sebelumnya, termasuk pemanfaatan teknik interpolasi konvensional sebagai metode pembanding [6] maupun penerapan *Convolutional Neural Network* (CNN) standar pada citra kompleks [5]. Namun, mayoritas pendekatan ini masih terpaku pada optimasi nilai matematis semata.


Metode konvensional seperti interpolasi Bicubic maupun arsitektur *Deep Learning* awal yang berbasis fungsi kerugian *Mean Squared Error* (MSE) memiliki keterbatasan mendasar. Meskipun metode-metode ini mampu menghasilkan nilai *Peak* meskipun memiliki nilai *Signal-to-Noise Ratio* (PSNR) yang tinggi, hasil rekonstruksi citra sering menunjukkan karakter visual terlalu halus (*oversmoothed*) dan kehilangan detail tekstur [1]. Fenomena ini terjadi karena minimalisasi MSE bekerja dengan merata-ratakan probabilitas piksel, sehingga gagal mempertahankan fitur visual tajam seperti serat kain atau vegetasi yang esensial bagi persepsi mata manusia [2].

Sebagai solusi atas permasalahan tersebut, *Super-Resolution Generative Adversarial Network* (SRGAN) menawarkan pendekatan revolusioner melalui skema *adversarial training* [1]. Berbeda dengan metode deterministik, SRGAN memanfaatkan Perceptual Loss digunakan untuk mendorong model menghasilkan detail tekstur yang lebih natural dan mendekati karakteristik citra asli, suatu pendekatan yang kemudian berkembang pada arsitektur generasi lanjutan seperti ESRGAN [4]. Penelitian ini bertujuan mengimplementasikan SRGAN untuk mengurangi efek blur yang umum

muncul pada pendekatan konvensional, dengan penekanan utama pada peningkatan kualitas perseptual visual (*perceptual quality*) meskipun harus menghadapi fenomena konsep perception–distortion trade-off yang menunjukkan bahwa peningkatan kualitas visual tidak selalu berbanding lurus dengan nilai PSNR [3].

2. Metode:

2.1. Alur Penelitian



2.2. Dataset dan Pra-pemrosesan

Dataset utama yang digunakan dalam eksperimen ini adalah DIV2K (Diverse 2K Resolution Images), yang merupakan salah satu standar paling umum dalam penelitian Super-Resolution. Dataset ini menyediakan citra resolusi tinggi dengan variasi objek, tekstur, serta

kondisi pencahayaan yang beragam, sehingga sangat representatif untuk evaluasi kinerja model SR.

Sebelum digunakan sebagai input model, data mentah diproses melalui beberapa tahapan praproses sebagai berikut.

- a. Tahap pertama adalah ekstraksi patch, di mana citra resolusi tinggi (HR) dipotong menjadi bagian-bagian kecil berukuran 128×128 piksel. Proses langkah ini dilakukan untuk memperbanyak variasi data pelatihan sekaligus mengoptimalkan penggunaan memori GPU selama pelatihan.
- b. Tahap kedua adalah degradasi (downsampling). Untuk mensimulasikan untuk membentuk citra beresolusi rendah (LR), setiap patch HR mengalami proses penurunan resolusi dengan faktor skala 2 menggunakan kernel bicubic. Proses ini menghasilkan pasangan data latih yang saling berkorespondensi antara citra LR dan HR.
- c. Tahap ketiga adalah normalisasi data. Nilai intensitas piksel citra yang semula berada pada rentang $[0, 255]$ dikonversi ke rentang floating point $[-1, 1]$. Normalisasi ini penting untuk mempercepat konvergensi selama proses pelatihan, khususnya karena lapisan output Generator menggunakan fungsi aktivasi Tanh.


2.3. Arsitektur Model

a. Generator Network

Generator dirancang untuk merekonstruksi citra super-resolusi (SR) yang memiliki karakteristik mendekati citra resolusi tinggi (HR) berdasarkan masukan citra beresolusi rendah (LR). Arsitektur generator mengadopsi konsep Deep Residual Network (ResNet) dengan beberapa komponen utama. Blok residual tersusun atas beberapa lapisan konvolusi yang menggunakan kernel berukuran 3×3 dengan 64 filter. Setiap lapisan konvolusi yang selanjutnya dipadukan dengan Batch Normalization (BN) serta mekanisme aktivasi non-linear Parametric ReLU (PReLU) untuk meningkatkan stabilitas pelatihan dan kemampuan representasi fitur.

Skip connection digunakan untuk menghubungkan fitur awal secara langsung ke fitur akhir. Mekanisme ini memungkinkan aliran gradien yang secara lebih stabil selama pelatihan, sehingga mampu menekan potensi terjadinya masalah vanishing gradient pada jaringan yang dalam.

Blok upsampling memanfaatkan lapisan PixelShuffle untuk meningkatkan dimensi spasial citra secara efisien. Metode ini dipilih karena mampu menghasilkan kualitas citra yang lebih baik serta meminimalkan artefak checkerboard yang sering muncul pada penggunaan transposed convolution.



Gambar 2.3.1. Gambar Generator Network


b. Discriminator Network

Discriminator berfungsi sebagai klasifikator yang bertugas membedakan apakah sebuah citra merupakan citra asli beresolusi tinggi (HR) atau citra palsu hasil rekonstruksi dari Generator (SR). Arsitektur Discriminator dirancang mengikuti pola VGG-style dengan peningkatan peningkatan jumlah filter dilakukan secara bertingkat, mulai dari 64 hingga 512, dengan tujuan mengekstraksi fitur visual yang semakin kompleks.

Proses reduksi dimensi citra dilakukan menggunakan strided convolution, sehingga ukuran spasial citra berkurang secara bertahap tanpa memerlukan lapisan pooling tambahan. Untuk fungsi aktivasi, digunakan LeakyReLU dengan nilai parameter $\alpha = 0.2$ yang bertujuan

mencegah terjadinya masalah dying ReLU serta menjaga aliran gradien tetap stabil.

Pada bagian akhir jaringan, digunakan lapisan Sigmoid untuk menghasilkan nilai probabilitas yang merepresentasikan tingkat keaslian citra, yaitu apakah citra tersebut termasuk citra HR asli atau citra SR hasil rekonstruksi Generator.



Gambar 2.3.2. Discriminator Network

2.4. Algoritma dan Strategi Pelatihan (*Training Strategy*)

Salah satu kontribusi utama dalam implementasi ini adalah penerapan strategi pelatihan dinamis yang membagi proses training ke dalam dua fase berdasarkan karakteristik fungsi kerugian (loss function) yang digunakan. Proses pelatihan memanfaatkan algoritma optimasi Adam dengan learning rate sebesar 10^{-4} .

Fase 1: Structural Learning (Epoch 1–25)

Pada fase awal pelatihan, tujuan utama adalah membentuk struktur global citra, seperti bentuk objek dan distribusi warna dasar, agar menyerupai citra asli. Fungsi kerugian pada fase ini didominasi oleh L1 Loss (Mean Absolute Error) yang dikombinasikan dengan Adversarial Loss, dengan formulasi sebagai berikut:

$$L_{total} = L_{L1} + \lambda L_{Adv}$$

Penggunaan L1 Loss efektif dalam meminimalkan kesalahan pada tingkat piksel, sehingga model dapat mencapai konvergensi lebih cepat dan menghasilkan nilai PSNR yang tinggi. Meskipun citra yang dihasilkan pada tahap ini cenderung tampak halus (smooth) dan kurang detail, fase ini berperan penting dalam membangun fondasi bobot Generator yang stabil dan kuat.

Fase 2: Perceptual Refinement (Epoch 26–Selesai)

Setelah struktur dasar citra terbentuk, proses pelatihan dilanjutkan dengan fokus pada pemulihan detail frekuensi tinggi, seperti tekstur halus pada rambut, rumput, atau serat kain. Pada fase ini, L1 Loss digantikan dengan mengganti fungsi kerugian menjadi VGG Loss (Perceptual Loss) yang dipadukan dengan Adversarial Loss, dengan persamaan sebagai berikut:

$$L_{total} = L_{VGG} + 10^{-3} L_{Adv}$$

VGG Loss tidak menghitung kesalahan berdasarkan perbedaan perbedaan nilai piksel secara langsung, tetapi dihitung melalui selisih feature maps yang diekstraksi dari jaringan VGG19 yang telah dilatih sebelumnya (pre-trained). Pendekatan ini mendorong Generator untuk tidak sekadar menghasilkan rata-rata warna yang aman, tetapi juga merekonstruksi pola tekstur yang lebih realistis, sehingga mampu menipu Discriminator dan memiliki kemiripan perseptual yang lebih tinggi dengan citra resolusi tinggi asli.

3. Dataset

Untuk mendukung proses pembelajaran model Super-Resolution yang menuntut rekonstruksi detail tekstur tingkat tinggi, penelitian ini menggunakan

dataset DIV2K (Diverse 2K Resolution Images). Dataset ini dipilih karena telah menjadi tolok ukur standar (state-of-the-art benchmark) dalam komunitas riset visi komputer, khususnya untuk tugas restorasi dan rekonstruksi citra.

3.1. Sumber dan Deskripsi Dataset

Dataset DIV2K pertama kali diperkenalkan oleh Agustsson dan Timofte pada ajang NTIRE 2017 Challenge on Single Image Super-Resolution yang diselenggarakan bersamaan dengan konferensi CVPR (Conference on Computer Vision and Pattern Recognition). Sejak diperkenalkan, DIV2K secara luas digunakan sebagai dataset referensi dalam evaluasi performa metode Super-Resolution modern.

Sesuai dengan nomenklaturanya, DIV2K memiliki karakteristik teknis yang membedakannya dari dataset citra konvensional seperti ImageNet atau COCO. Karakteristik tersebut antara lain sebagai berikut.

a. Resolusi definisi tinggi (2K).

Setiap citra dalam dataset DIV2K memiliki setidaknya satu dimensi, baik lebar maupun tinggi, yang mencapai sekitar 2.000 piksel. Resolusi yang sangat tinggi ini berperan penting sebagai ground truth, sehingga model dapat mempelajari dan merekonstruksi fitur frekuensi tinggi secara lebih akurat.

b. Keragaman konten (diversity).

Dataset ini dirancang untuk mencakup spektrum visual yang luas, mulai dari objek biotik seperti manusia, flora, dan fauna, hingga objek abiotik seperti arsitektur perkotaan, transportasi, dan tekstil. Keragaman ini penting untuk memastikan bahwa model Super-Resolution tidak bias terhadap jenis objek atau tekstur tertentu, serta mampu melakukan generalisasi dengan baik pada berbagai kondisi visual.

3.2. Distribusi dan Strategi Penggunaan Data

Secara standar, dataset DIV2K terdiri dari 1.000 citra yang terbagi ke dalam tiga partisi, yaitu 800 citra untuk pelatihan (train), 100 citra untuk validasi (validation), dan 100 citra untuk pengujian (test).

Namun, dalam penelitian ini diterapkan strategi distribusi data yang disesuaikan untuk memaksimalkan stabilitas proses pelatihan Generative Adversarial Network (GAN), yang secara umum membutuhkan volume data latih yang besar dan beragam. Strategi distribusi data yang digunakan adalah sebagai berikut.

a. Data Latih (*Training Corpus*):

Penelitian ini menggabungkan partisi Train (0001–0800) dan Validation (0801–0900) ke dalam satu dataset pelatihan dengan total 900 citra resolusi tinggi. Penggabungan ini bertujuan untuk memperkaya variasi fitur tekstur yang dipelajari oleh Generator, mengurangi risiko terjadinya mode collapse, serta memberikan eksposur yang lebih luas terhadap pola-pola visual yang kompleks selama proses pelatihan.



Gambar 3.2.1. 5 Contoh Data Training

b. Data Uji (*Testing Set*):

Untuk menjaga objektivitas evaluasi dan mencegah terjadinya kebocoran data (data leakage) akibat penggabungan data latih, pengujian kinerja model tidak dilakukan menggunakan citra dari

dataset DIV2K yang telah digunakan pada tahap pelatihan. Sebagai gantinya, evaluasi model dilakukan menggunakan dataset eksternal (unseen data), yang terdiri dari dua kategori.

- 1) Pertama, dataset standar industri, yaitu Set5 dan Set14, yang digunakan untuk evaluasi kuantitatif berdasarkan metrik objektif seperti PSNR dan SSIM.




4. Hasil Pengujian

4.1 Skenario Pengujian

Pengujian dilakukan untuk mengevaluasi kinerja model Super-Resolution Generative Adversarial Network (SRGAN) yang telah dilatih menggunakan dataset DIV2K, dengan tujuan mengukur kemampuan model dalam merekonstruksi citra beresolusi tinggi dari citra beresolusi rendah.

Skenario pengujian yang diterapkan adalah sebagai berikut:

1. Model diuji menggunakan dataset eksternal (unseen data), yaitu Set5 dan Set14, guna memastikan kemampuan generalisasi model dan menghindari *data leakage*.
2. Jumlah total sampel pengujian adalah 13.743 citra.
3. Proses evaluasi dijalankan pada perangkat GPU (CUDA) dengan ukuran batch 8.
4. Model dievaluasi pada setiap checkpoint epoch ke-1 hingga epoch ke-40.
5. Metode bicubic interpolation digunakan sebagai baseline pembandingan.
6. Metrik evaluasi kuantitatif yang digunakan meliputi:
 - i. Peak Signal-to-Noise Ratio (PSNR)
 - ii. Structural Similarity Index Measure (SSIM)




Selain evaluasi numerik, beberapa hasil citra keluaran model disimpan untuk keperluan observasi visual dan analisis kualitatif.

4.2 Hasil Pengujian

Berdasarkan hasil pengujian yang telah dilakukan, diperoleh ringkasan hasil sebagai berikut:

- Nilai PSNR bicubic interpolation bersifat konstan pada 35.17 dB.
- Nilai SSIM bicubic interpolation bersifat konstan pada 0.9096.
- Nilai PSNR SRGAN menunjukkan variasi pada rentang 30.65 dB hingga 36.50 dB.
- Nilai SSIM SRGAN berada pada rentang 0.8659 hingga 0.9375.



Ini adalah grafik PSNR SRGAN vs Epoch (dengan Bicubic sebagai baseline)

Model SRGAN mencapai performa terbaik pada beberapa epoch tertentu, antara lain:

- Epoch 12 dengan PSNR 36.50 dB dan SSIM 0.9375.
- Epoch 19 dengan PSNR 36.03 dB dan SSIM 0.9291.
- Epoch 22 dengan PSNR 36.28 dB dan SSIM 0.9295.

Pada epoch terakhir (epoch 40), model menghasilkan PSNR sebesar **32.78 dB** dan SSIM sebesar **0.9029**.

5. Analisa Hasil

5.1 Fluktuasi Nilai PSNR dan SSIM

Nilai PSNR dan SSIM pada model SRGAN tidak menunjukkan tren peningkatan yang linear seiring bertambahnya epoch. Fenomena ini merupakan karakteristik umum dari model berbasis Generative Adversarial Network (GAN), di mana proses pelatihan melibatkan kompetisi antara Generator dan Discriminator. Ketika Generator berhasil menghasilkan citra yang semakin realistis, Discriminator akan menyesuaikan bobotnya untuk tetap mampu membedakan citra asli dan citra hasil rekonstruksi.

5.2 Pengaruh Strategi Pelatihan Dua Fase

Pada fase awal pelatihan (Structural Learning), penggunaan L1 Loss mendorong model untuk mempelajari struktur global citra sehingga nilai PSNR cenderung meningkat. Namun, setelah memasuki fase Perceptual Refinement, di mana VGG Loss digunakan, model mulai memprioritaskan kemiripan perseptual dan detail tekstur frekuensi tinggi.

Perubahan fokus optimasi ini menyebabkan nilai PSNR pada beberapa epoch menurun, meskipun kualitas visual citra hasil rekonstruksi meningkat. Hal ini sejalan dengan konsep perception-distortion trade-off, di mana peningkatan kualitas perseptual tidak selalu berbanding lurus dengan metrik kesamaan piksel.

5.3 Perbandingan dengan Metode Bicubic

Secara kuantitatif, bicubic interpolation memiliki nilai PSNR yang stabil dan relatif tinggi. Namun, metode ini tidak mampu merekonstruksi detail tekstur kompleks. Sebaliknya, SRGAN mampu menghasilkan tekstur yang lebih tajam dan realistis, meskipun pada beberapa kondisi menghasilkan nilai PSNR yang lebih rendah. Dengan demikian, SRGAN lebih unggul dalam aspek kualitas visual perseptual, sedangkan bicubic lebih unggul dalam keseragaman nilai numerik.

5.4 Penentuan Epoch Optimal

Berdasarkan hasil pengujian, rentang epoch 12 hingga 22 dapat dianggap sebagai fase optimal model, karena menghasilkan kombinasi nilai PSNR dan SSIM yang tinggi sebelum model memasuki fase tekstur agresif pada epoch selanjutnya. Oleh karena itu, checkpoint pada rentang epoch tersebut lebih direkomendasikan untuk penggunaan inferensi.

6. Kesimpulan

Berdasarkan implementasi, pengujian, dan analisa hasil yang telah dilakukan, dapat disimpulkan bahwa:

1. Model SRGAN berhasil diimplementasikan dan dilatih secara stabil menggunakan dataset DIV2K dengan strategi pelatihan dua fase.
2. SRGAN mampu menghasilkan citra super-resolution dengan kualitas struktural dan perseptual yang lebih baik dibandingkan metode interpolasi konvensional.
3. Nilai PSNR dan SSIM pada SRGAN bersifat fluktuatif akibat mekanisme adversarial, namun fenomena ini merupakan karakteristik inheren dari pendekatan generatif.
4. Epoch 12–22 merupakan rentang pelatihan paling optimal berdasarkan evaluasi kuantitatif.

Secara keseluruhan, SRGAN lebih sesuai digunakan untuk aplikasi yang menekankan kualitas visual dan realisme tekstur, bukan sekadar optimasi kesamaan piksel.

7. Referensi

- [1] C. Ledig *et al.*, "Photo-Realistic Single Image Super-Resolution Using a Generative Adversarial Network," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017, pp. 4681–4690. (*Paper utama penemu SRGAN*)
- [2] J. Johnson, A. Alahi, and L. Fei-Fei, "Perceptual losses for real-time style transfer and super-resolution," in *European Conference on Computer Vision (ECCV)*, 2016, pp. 694–711. (*Dasar penggunaan VGG Loss*)
- [3] Y. Blau and T. Michaeli, "The perception-distortion tradeoff," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018, pp. 6228–6237. (*Argumen untuk membela nilai PSNR yang turun*)
- [4] X. Wang *et al.*, "ESRGAN: Enhanced super-resolution generative adversarial networks," in *European Conference on Computer Vision (ECCV) Workshops*
- [5] M. A. Abdulfattah, "Super Resolution pada Citra Udara menggunakan Convolutional Neural Network," *ELKOMIKA: Jurnal Teknik Energi Elektrik, Teknik Telekomunikasi, & Teknik Elektronika*, vol. 9, no. 1, pp. 167–174, 2021.
- [6] B. Hardiansyah, A. P. Armin, dan A. B. Yunanda, "Rekonstruksi Citra Pada Super Resolusi Menggunakan Interpolasi Bicubic," *INTEGER: Journal of Information Technology*, vol. 3, no. 2, pp. 29–36, 2018.
- [7] K. Simonyan dan A. Zisserman, "Very Deep Convolutional Networks for Large-Scale Image Recognition," *International Conference on Learning Representations (ICLR)*, 2015.
→ (*Referensi arsitektur VGG19 yang digunakan pada perceptual loss*)

8. Kontribusi & distribusi anggota kelompok

No	Nim	Nama	Kontribusi
1.	23.11.5583	Reynald Aryansyah	• Mengembangkan arsitektur utama model <i>Neural Network</i> (Generator dan Discriminator) berbasis ResNet dan VGG-style. • Menyusun dan mengimplementasikan algoritma pelatihan dua fase (<i>Structural Learning</i> dengan L1 Loss dan <i>Perceptual Refinement</i> dengan VGG Loss). • Menganalisis grafik kurva pelatihan (<i>loss curves</i>) untuk memastikan konvergensi model.
2.	23.11.5567	Ahmad Rafdy Ramadhan	• Mengelola konfigurasi lingkungan pengembangan (<i>environment setup</i>) dan dependensi pustaka (<i>library</i>). • Mengintegrasikan data hasil eksperimen dan visualisasi grafik ke dalam analisis Bab Hasil dan Pembahasan. • Menyusun dokumentasi teknis akhir serta materi presentasi proyek.
3.	23.11.5575	M Noer Attalah Dzahkwan	• Mengembangkan skrip evaluasi otomatis untuk mengukur kinerja model.

			• Menghitung dan memvalidasi metrik standar industri (PSNR dan SSIM) pada dataset pengujian (Set5 dan Set14). • Menyusun perbandingan visual kualitatif (<i>visual comparison</i>) antara hasil rekonstruksi model dengan citra asli.
4.	23.11.5579	Andri Laksono	• Bertanggung jawab atas pra-pemrosesan data, termasuk teknik ekstraksi <i>patch</i> citra, normalisasi, dan <i>downsampling</i> (HR ke LR). • Melakukan inspeksi dan validasi kualitas dataset sebelum digunakan dalam pelatihan. • Mengembangkan modul inferensi untuk menguji model pada data gambar nyata di luar dataset latih.